UNIVERSIDAD ICESI · ESTRUCTURAS DISCRETAS III

ResumeLens

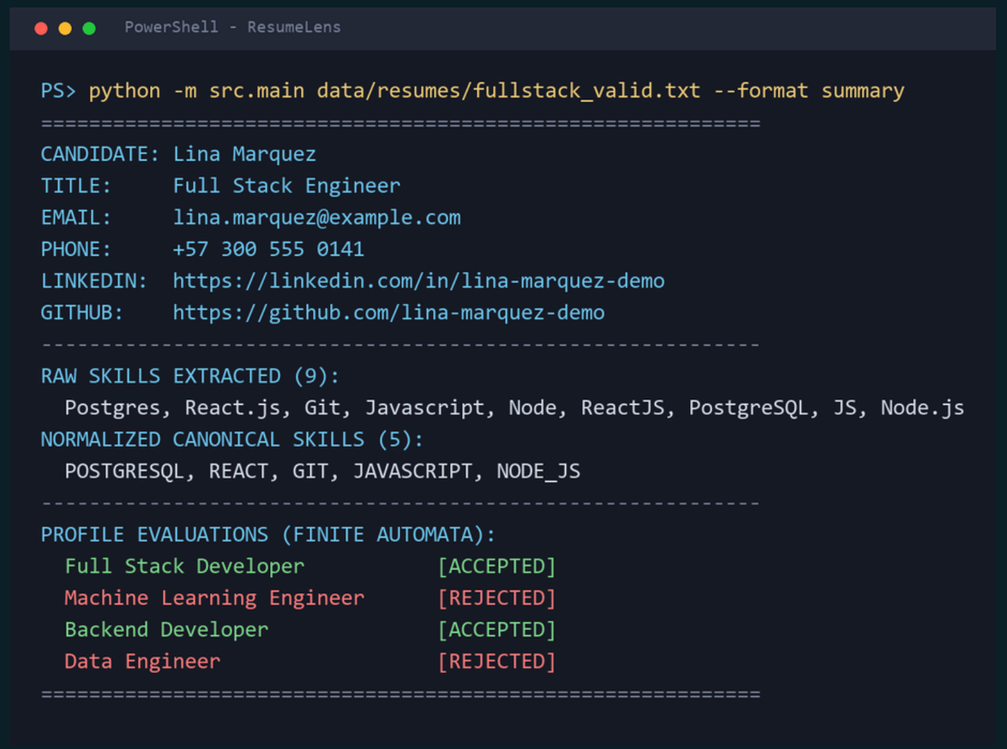
Screening formal de hojas de vida con regex, transductores y autómatas

Nicolás Buelvas — Etapas 1–2

Daniel Nastul — Etapas 3–4

Albert Valencia — Visualización

Profesor: Andrés Aristizábal · Grupo 3



De texto libre a una decisión explicable

TXT

Texto libre

Un CV en .txt, sin estructura

{ }

Estructura formal

Datos y habilidades canónicas

OK

Decisión

Perfil aceptado o rechazado

Meta: aplicar teoría de lenguajes formales a un problema real de selección.

Un pipeline de 5 etapas



4 perfiles evaluados: Full Stack · Machine Learning · Backend · Data Engineer

La entrada: un CV sintético

data/resumes/fullstack_valid.txt

```
Lina Marquez
Full Stack Engineer
lina.marquez@example.com
Phone: +57 300 555 0141
LinkedIn: https://linkedin.com/in/lina-marquez-demo
GitHub: https://github.com/lina-marquez-demo
Portfolio: https://lina-marquez.example.com

TECHNICAL SKILLS
Postgres | React.js | Git | Javascript | Node | ReactJS | PostgreSQL | JS | Node.js
```

data/resumes/fullstack_valid.txt (fragmento real)

6 CVs ficticios

4 perfiles objetivo

1 Extracción con regex

src/extraction/regex_patterns.py

```python
EMAIL_PATTERN = re.compile(
    r"\b[A-Za-z0-9._%+-]+@[A-Za-z0-9.-]+\.[A-Za-z]{2,}\b"
)

PHONE_PATTERN = re.compile(
    r"(?:(?:\+|00)\d{1,3}[\s.-]?)?(?:\(?\d{2,4}\)?[\s.-]?)?\d{3,4}[\s.-]?\d{3,4}\b"
)

LINKEDIN_PATTERN = re.compile(
    r"(?:https?://)?(?:www\.)?linkedin\.com/in/([A-Za-z0-9_-]+)/?",
    re.IGNORECASE,
)

GITHUB_PATTERN = re.compile(
    r"(?:https?://)?(?:www\.)?github\.com/([A-Za-z0-9_-]+)/?",
    re.IGNORECASE,
)
```

Contacto

Email y teléfono

Perfiles

LinkedIn y GitHub

Experiencia

Años y resumen

2 Normalización con FST

src/normalization/skill_transducers.py

```python
SOFTWARE_SKILL_SYNONYMS: Dict[str, str] = {
    # Frontend frameworks
    "React": "REACT",
    "React.js": "REACT",
    "ReactJS": "REACT",
    "react": "REACT",
    "react.js": "REACT",
    ...
    # Backend frameworks
    "Node": "NODE_JS",
    "Node.js": "NODE_JS",
    "NodeJS": "NODE_JS",
    "node.js": "NODE_JS",
```

9 → 5

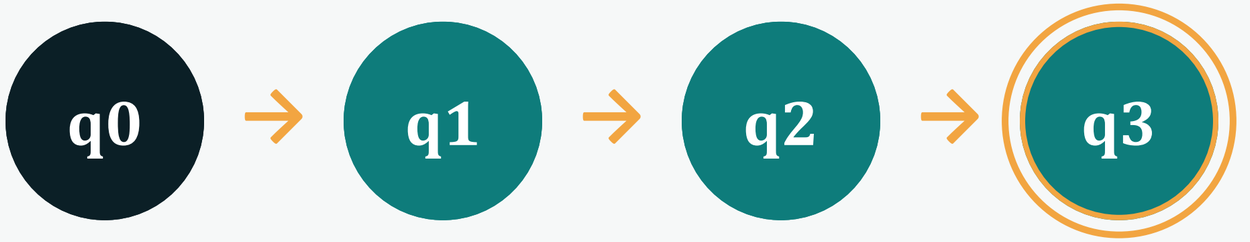
skills extraídas → skills canónicas

```
ReactJS · React.js  →  REACT
Node · Node.js  →  NODE_JS
JS · Javascript  →  JAVASCRIPT
```

3 Perfiles con autómatas (DFA)

src/recognition/software_automata.py

```python
def _build_backend_dfa(self):
    for r in roles_and_langs:
        transitions.extend([
            ("q0_start", r, "q1_be_tech"),
            ("q1_be_tech", r, "q1_be_tech")
        ])
    # ...
    for db in databases:
        transitions.extend([
            ("q1_be_tech", db, "q2_db"),
            ("q2_db", db, "q2_db")
        ])
    # ...
    return builder.build_automaton(
        start_state="q0_start",
        transitions=transitions,
        final_states=["q3_tools"]
    )
```



Un DFA por perfil
Entrada: tokens canónicos. Salida: ACCEPTED o REJECTED.

4 DSL con textX

Gramática

src/dsl/grammar/resume.tx

```
ResumeModel:
    'CANDIDATE_PROFILE' name=STRING
    'TITLE:' title=STRING
    contact=ContactInfo
    'EXPERIENCE:' experiences*=Experience
    'EDUCATION:' education*=Education
    'SKILLS:' skills+=STRING[',']
    'EVALUATIONS:' evaluations+=ProfileEvaluation
;

ProfileEvaluation:
    profile=STRING ':' status=StatusType
;

StatusType:
    'ACCEPTED' | 'REJECTED'
;
```

Modelo serializado (salida real)

PowerShell - ResumeLens

```
PS> python -m src.main data/resumes/fullstack_valid.txt --format dsl
CANDIDATE_PROFILE "Lina Marquez"
TITLE: "Full Stack Engineer"
CONTACT
email= "lina.marquez@example.com"
phone= "+57 300 555 0141"
github= "https://github.com/lina-marquez-demo"
linkedin= "https://linkedin.com/in/lina-marquez-demo"
EXPERIENCE:
EDUCATION:
SKILLS: "POSTGRESQL", "REACT", "GIT", "JAVASCRIPT", "NODE_JS"
EVALUATIONS:
"Full Stack Developer" : ACCEPTED
"Machine Learning Engineer" : REJECTED
"Backend Developer" : ACCEPTED
"Data Engineer" : REJECTED
```

5 Reportes HTML y Markdown



Habilidades

- POSTGRESQL
- REACT
- GIT
- JAVASCRIPT
- NODE_JS

Clasificación de perfiles

- Full Stack Developer: Aceptado
- Machine Learning Engineer: Rechazado
- Backend Developer: Aceptado
- Data Engineer: Rechazado

Reporte HTML generado (sección de clasificación)

HTML

Reporte visual por candidato

Markdown

Resumen para documentación

DSL

Modelo estructurado

```
python -m src.main … --format all
```

Demo: todo el dataset en un comando

PowerShell - ResumeLens

```
PS> python -m src.main --demo
Running ResumeLens evaluation across dataset:
RESUME FILE                    CANDIDATE              ACCEPTED PROFILES
-------------------------------------------------------------------------------
backend_sample.txt             Sara Beltran           Backend Developer
data_engineer_sample.txt       Rafaela Quintero       Data Engineer
fullstack_invalid.txt          Mateo Rios             Backend Developer
fullstack_valid.txt            Lina Marquez           Full Stack Developer, Backend Developer
ml_engineer_invalid.txt        Dario Pineda           Backend Developer, Data Engineer
ml_engineer_valid.txt          Celeste Arboleda       Machine Learning Engineer, Backend Developer
-------------------------------------------------------------------------------
```

6 CVs → 6 resultados, sin intervención manual

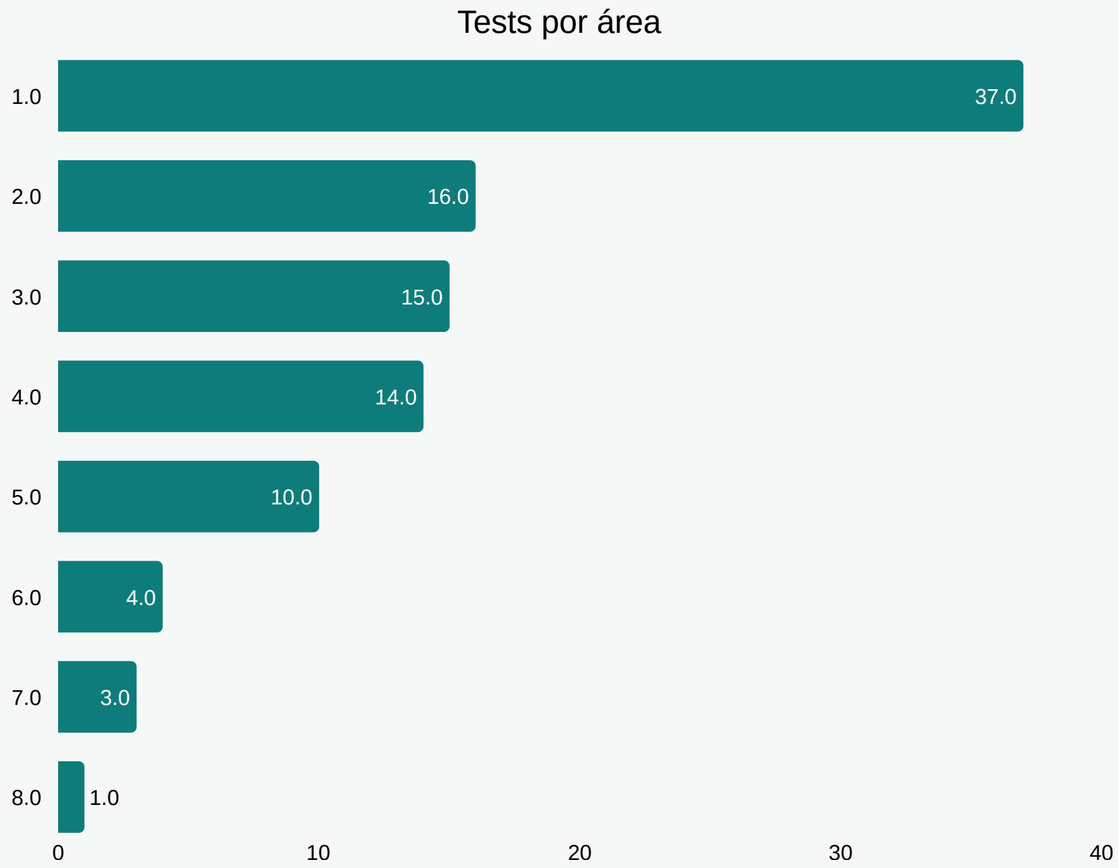
Pruebas: 100 de 100 pasan

```
PowerShell - ResumeLens

PS> python -m pytest -q
.......................................................................... [ 72%]
............................                                               [100%]
100 passed in 1.61s
```

100

tests automáticos
unitarios, de pipeline
y end-to-end



Lo logrado y lo que mejoraríamos

Logramos

- Pipeline de 5 etapas funcionando
- 100 tests en verde
- Reportes HTML y Markdown

Mejoraríamos

- Perfiles más excluyentes: Backend acepta de más
- Experiencia y educación aún vacías en el DSL
- Dataset más grande que 6 CVs

ACCEPTED indica que el autómata aceptó la secuencia; no prueba aptitud real.

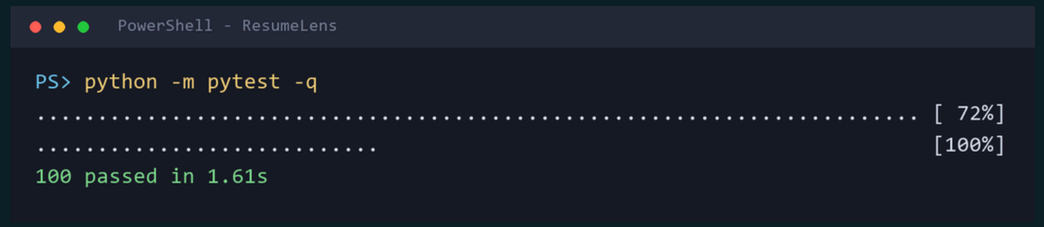
¡Gracias!

¿Preguntas?

5
etapas

4
perfiles

100
tests



Nicolás Buelvas · Daniel Nastul · Albert Valencia

github.com/nicolasbuelvas/IntegrativeTask_AlbertoIA